

基于学习光学技术的离焦深度测量方法：适用于成像及遮挡感知深度估计

池间博、Cindy M. Nguyen、Christopher A. Metzler、*IEEE* 会员彭一帆、*IEEE* 会员以及Gordon Wetzstein、*IEEE* 高级会员

摘要——尽管在仅利用图像深度线索的神经网络架构方面已取得显著进展，单目深度估计仍是一个具有挑战性的难题。本研究受到散焦深度测量及新兴点扩散函数工程方法的启发。

为实现可编程光学系统与深度估计网络的端到端优化，我们提出了一种基于学习获得的相位编码孔径、用于从单张RGB图像进行深度估计的新型改进框架。该优化孔径设计采用旋转对称约束以提升计算效率；同时，我们通过一种具备遮挡感知功能的图像生成模型联合训练光学系统与神经网络，该模型在深度不连续区域能产生比现有技术更精确的离焦模糊效果。通过采用该框架及定制原型相机，我们在仿真与实验中证明了这种端到端优化的计算相机在图像与深度估计质量方面达到了当前最先进的水平。

索引术语—— 计算摄影学、计算光学

1 引言

稳健的深度感知是一项极具挑战性但至关重要的能力，广泛应用于机器人技术[1]、[2]、自动驾驶[3][4][5][6]、增强现实[7]及三维摄影[8]等领域的计算机视觉与图像处理问题。现有基于飞行时间、立体图像或对结构化照明的技术方案均需要高功率照明设备和复杂的硬件系统，这使得仅通过单张二维图像实现单目深度估计（MDE）[9][10][11][12][13][14][15][16][17][18][19]成为最具吸引力的解决方案之一。

MDE 方法通常依赖于图像深度线索，例如透视效果、部分遮挡以及通过监督式训练从图像数据集中习得的物体相对尺寸。这些上下文线索能可靠地帮助确定场景中物体的相对顺序[10][16]。离焦模糊是另一种互补的深度感知线索，已被广泛应用于基于离焦（DfD）的方法中[20][21][22][23][24]。近期的DfD方法还提出了能够同时学习图像特征与深度信息的网络架构[25]。然而，离焦线索本身具有模糊性，因此许多计算摄影技术采用编码光圈设计来调控离焦模糊效果，从而在光学层面编码比传统离焦模糊所能承载的信息量更多的细节[26][27][28][29]。近年来，通过端到端（E2E）优化光学系统与图像处理算法，手工设计的光圈方案已得到显著改进[30][31][32]。

尽管现有的端到端编码孔径 MDE 技术已被证明效果良好，但这些方法并未充分利用可用的单眼深度线索。具体而言，这些方法所采用的线性光学图像生成模型[30]、[31]、[32]无法准确模拟遮挡边界处的离焦模糊现象。因此，先前的研究仅依赖于局部深度恒定区域内的离焦信息。这一点在业内已是公认的事实。

然而，视觉科学界认为，离焦模糊效应以及遮挡边缘所隐含的空间关系，为人类视觉提供了比图像线索更为显著的深度感知信息[33]、[34]、[35]。

为弥补DfD方法的这一缺陷，我们提出了一种非线性、具备遮挡感知能力的光学图像生成算法，其对遮挡边界处离焦模糊的建模精度优于以往端到端（E2E）方法。此外，我们采用旋转对称设计的优化相位编码孔径结构，使优化过程的计算复杂度和内存需求降低了一个数量级。最后，我们推导出一种有效的预处理方法：通过对光学图像生成模型进行近似逆运算来处理传感器测量数据。这种近似逆运算显著提升了 MDE 网络从编码后的传感器图像中稳健地推断深度图的能力。我们的方法在估算深度图的同时，还能从单一光学编码传感器图像中生成全焦图像，这一特性具有独特的鲁棒性。这对于需要同时利用图像和深度信息的直接观察或下游任务（如分类或目标检测）至关重要。

具体而言，我们的贡献如下：

- 我们采用一种具备遮挡感知功能的图像生成模型、旋转对称孔径以及有效的预处理方法，构建了相位编码孔径与 MDE 网络的端到端优化方案。
- 我们对所提出的框架进行了分析，并证明在采用相似网络架构的情况下，该框架的表现优于标准方法及端到端（E2E）MDE 方案。
- 我们开发了一款相机原型机，其光圈内装有定制制造的衍射光学元件（DOE），并展示了该设备在室内外场景下的性能表现及高质量 RGBD 视频录制能力。

2 相关工作

2.1 单目深度估计（MDE）

深度学习是 MDE 领域极具吸引力的方法，因为神经网络能够在深度估计过程中识别出人类无法察觉的特征。

- H. Ikoma、C. M. Nguyen、Y. Peng 和 G. 韦茨斯坦（Wetzstein）任职于斯坦福大学电气工程系；C.A. 梅茨勒（C. A. Metzler）则就职于马里兰大学计算机科学系。

- 项目网站：<https://www.computationalimaging.org>

针对 MDE 问题, 已有多钟深度学习方法被提出, 这些方法采用了定制损失函数[10][13]、局部与全局约束[16][36][37]以及不同层级的监督机制[38][39][40]。基于几何特征的方法通过条件随机场[41]、双流CNN[42]和视频三维重建[43]实现表面法线估计与深度估计的联合处理, 在 KITTI [44]和NYU Depth[45]等数据集上均展现出优异性能。其他方法包括相对深度图估计[46]及利用频谱域增强估计效果[47]。为提升跨数据集的泛化能力, 先前研究还整合了相机物理参数(如散焦模糊[25][48]、焦距[49]及其他传感器信息[50]), 以利用其隐含的深度线索编码特性。本文提出一种计算光学方法, 可联合优化相位编码孔径与神经网络, 实现单张图像的被动式三维成像。

2.2 用于深度估计的计算成像技术

与依赖单一二维图像不同, DfD的多种变体通过使用求和修正拉普拉斯算子[51]、空间域卷积变换[52]以及二次似然函数[53]来捕获并处理两张或多张图像。双像素传感器也被证明能够采集具有足够视差的立体图像对以估算深度[54]。振幅编码[26][27][55]和相位编码[56][57]的孔径技术也已被广泛研究, 这些技术利用色差原理实现深度估计[23]。然而, 大多数此类方法仍采用传统镜头或手工设计的孔径结构及算法, 未能以端到端的方式优化系统性能。

2.3 深光学

在色彩滤光片设计[58]、光谱成像[59]、超分辨率定位显微技术[60]、超分辨率单光子成像[61]、扩展景深技术[62]、消色差成像[63]、高动态范围(HDR)成像[64][65]、图像分类[66]以及视频压缩感知[67][68]等领域, 研究人员已联合开发了光学系统、传感器电子器件及网络技术。关于人工智能在光学领域应用的最新综述可参阅文献[69]。

近期, 学界还提出了联合优化相机光学系统与深度估计网络的原理性方法。例如, Haim等人[31]在相位掩模中采用同心环结构来产生色差; Wu等人[30]则在其联合优化的相位掩模与基于CNN的重建算法中利用了离焦线索; Chang等人[32]采用端到端优化方法设计了适用于该任务的自由曲面镜头。此外, 深度光学技术也被扩展应用于从传感器测量数据中提取深度图及多光谱场景信息[70]。

受深度光学技术理念的启发, 我们提出了一种全新的端到端深度成像方法, 该方法在该领域现有技术[30]、[31]、[32]基础上实现了多项重要改进。首先, 我们引入了一种具备遮挡感知功能的图像生成模型, 显著提升了对遮挡边界处离焦模糊现象的建模与光学编码能力; 其次, 我们提出了一种预处理方案, 在将数据输入深度估计网络之前, 先应用非线性图像生成模型的近似逆运算。最后, 我们将近期为采用单一DOE实现消色差成像而提出的旋转对称光学设计[63]进行了针对性调整, 以适应该应用需求。

采用相位编码孔径的 MDE 技术。我们的框架能够从单张编码传感器图像中同时重建RGB图像和深度图, 其分辨率和精度均显著优于相关研究的估计结果。

3 相位编码 3D 成像系统

本节阐述了我们的端到端(E2E)训练流程, 涵盖从图像生成模型到基于神经网络的重建算法的全过程。我们采用了一种配备可学习相位编码光圈的相机, 以及一个卷积神经网络(CNN), 该网络能够从带有编码景深信息的原始传感器图像中同时生成全焦(AiF)RGB图像和深度图。该训练流程如图1所示。

3.1 径向对称点扩散函数

与大多数相机一样, 我们的相机由传感器和一个常规的摄影复合镜头组成, 该镜头将场景成像到传感器上。我们通过对该光学系统进行改进, 在其光圈平面上增加了DOE元件。这种相位编码孔径技术使我们能够通过调节DOE(探测元件)表面高度的变化, 直接控制成像系统的深度依赖性点扩散函数(PSF)。本节所述的端到端优化流程旨在寻找一种表面轮廓: 该轮廓能塑造PSF的形态, 使其便于卷积神经网络(CNN)从单张图像中准确估算每个像素的场景深度与颜色信息。

PSF 的建模方法如 [71] 所述。

$$\text{PSF}(\rho, z, \lambda) = \left| \frac{2\pi}{\lambda s} \int_0^\infty r D(r, \lambda, z) P(r, \lambda) J_0(2\pi \rho r) dr \right|^2. \quad (1)$$

此处, ρ 和 r 分别表示传感器平面与孔径平面上的径向距离, λ 为波长, $J_0(\cdot)$ 表示第一类贝塞尔函数零阶。在此公式中, 焦距为 f 的相机镜头聚焦于距离 d 处。高斯薄透镜公式如下: $\frac{1}{f} = \frac{1}{d} + \frac{1}{s}$ 将这些量与镜头和传感器之间的距离 s 相关联。离焦因子 $D(r, \lambda, z)$ 用于模拟距镜头一定距离 z 处某一点的点扩散函数(PSF)深度变化, 其表达式为:

$$D(r, \lambda, z) = \frac{z}{\lambda(r^2 + z^2)} e^{i \frac{2\pi}{\lambda} (\sqrt{r^2 + z^2} - \sqrt{r^2 + d^2})}. \quad (2)$$

我们采用径向对称的DOE设计[63], 与非对称设计相比, 该设计可将PSF需要优化的DOE参数数量、内存需求及计算时间降低一个数量级。最后, 孔径平面上的相位延迟 P 与折射率为 $n(\lambda)$ 的DOE表面轮廓 h 相关联。

$$P(r, \lambda) = a(r) e^{i \frac{2\pi}{\lambda} (n(\lambda) - n_{\text{air}}) h(r)}, \quad (3)$$

其中 $n_{\text{air}} \approx 1.0$ 为空气的折射率, 而 a 是相位掩模的透射率; 该值通常为1, 但也可能包含遮光区域, 这些区域会将局部透射率设为0。

我们在补充材料中提供了这些公式的更详细推导过程。尽管这些方程基于标准光学模型[71], 但在补充材料中, 我们推导出了—种新颖的公式, 使得能够高效计算等式1的积分。




图1. E2E优化框架示意图。训练集的 RGBD 图像与由镜头表面轮廓 h 生成的深度依赖性3D点扩散函数（PSF）进行卷积运算，随后通过alpha合成技术进行融合。生成的传感器图像 b 在输入卷积神经网络（CNN）前，会先经过基于近似逆变换的预条件化处理。系统会对最终得到的RGB图像和深度图同时应用损失函数 L ；计算出的误差将反向传播至CNN参数及相位编码孔径的表面轮廓参数中。

3.2 具有遮挡效应的图像形成模型

先前关于用于瞬时三维成像的端到端（E2E）优化相位编码孔径的研究[30][31][32]，采用了某种简单线性图像形成模型的变体，其形式如下：

$$b(\lambda) = \sum_{k=0}^{K-1} \text{PSF}_k(\lambda) * l_k(\lambda) + \eta, \quad (4)$$

其中 $*$ 表示二维卷积运算符， $b(\lambda)$ 代表传感器图像的单一波长， η 为加性噪声。在该模型中，输入的 RGBD 图像被量化为 K 层深度结构 l_k ，其中 $k=0$ 表示最底层。

线性模型能够精确再现局部深度值恒定的图像区域中的离焦模糊效果。然而，该方法无法准确模拟深度不连续处的离焦模糊现象。这些深度边缘处的离焦模糊对人类深度感知至关重要[33][35]——我们认为 MDE 网络同样能从更精确的深度边缘离焦模糊建模中获益。为此，我们采用基于alpha合成技术[72][73][74]的非线性可微分图像生成模型，并将其与我们提出的波长及深度依赖型点扩散函数（PSF）相结合。

$$b(\lambda) = \sum_{k=0}^{K-1} \tilde{l}_k \prod_{k'=k+1}^{K-1} (1 - \tilde{\alpha}_{k'}) + \eta, \quad (5)$$

其中 $\tilde{l}_k := (\text{PSF}_k(\lambda) * l_k) / E_k(\lambda)$ 且 $\tilde{\alpha}_k := (\text{PSF}_k(\lambda) * \alpha_k(\lambda)) / E_k(\lambda)$ 。深度图被量化为 K 个深度层，以生成二值掩膜 α_k 。由于直接使用子图像 l_k 和二值掩膜 α_k 对PSF进行卷积运算，会导致深度层过渡处的能量或亮度出现不真实的衰减。因此，为恢复该特性，我们采用归一化因子 $E_k(\lambda) := \text{PSF}_k * \sum_{k'=0}^{K-1} \alpha_{k'}$ 。我们通过快速傅里叶变换（FFT）实现卷积运算，并在边界裁剪32个像素以减少可能的边界伪影。

如图2所示，我们的非线性模型相较于先前使用的线性模型，能从 RGBD 输入生成更逼真的散焦图像。与Wu等人[30]和Chang等人[32]的研究相比，我们的模型在深度不连续区域的改进尤为显著，这使得下游网络能够获得更优质的散焦信息；与直接线性模型相比，我们的模型在纹理和深度边缘处产生的散焦模糊效果更为精确。图2所示的误差图是基于光线追踪的真实传感器图像计算得出的。需要注意的是：




图2. 比较了两种模拟RGB图像（左上）和深度图（右上）中离焦模糊的图像生成模型。现有的线性模型（包括Wu等人[30]和Chang等人[32]提出的变体）均未能充分模拟深度不连续处的模糊现象。而我们的非线性遮挡感知模型能够更准确地逼近光线追踪生成的真实图像。

光线追踪是验证这些不同图像生成模型的重要工具，但并不适用于系统训练的可行方法。在训练过程中实时进行光线追踪耗时过长，且无法预先计算出所有可能相位编码孔径设置下的每张光线追踪图像。更多讨论内容请参阅补充材料。

3.3 基于CNN的图像与深度估计方法

在端到端（E2E）训练中，我们采用卷积神经网络（CNN）同时生成全焦图像与深度图或 RGBD 图像。下文将详细阐述其架构及训练流程。

3.3.1. 使用近似逆矩阵进行预处理

尽管等式中概述的线性图像形成模型4在遮挡边界处并不精确，但它提供了一个足够简单的框架，可作为我们网络的预处理步骤。具体而言，我们构建了逆问题：从单一输入中寻找多平面表示 $l^{(est)} \in \mathbb{R}^{N \times M \times K}$ 。

二维传感器图像可视为具有正则化参数 γ 的Tikhonov正则化最小二乘问题

$$l^{(est)} = \arg \min_{l \in \mathbb{R}^{M \times N \times K}} \left\| b - \sum_{k=0}^{K-1} \text{PSF}_k * l_k \right\|^2 + \gamma \|l\|^2. \quad (6)$$

为简化符号表示，本文省略了波长依赖性。在补充材料中，我们推导出了频域内该逆问题的闭式解。该解通过快速傅里叶变换（FFT）实现，并采用边缘平滑预处理步骤以减少振铃伪影[75]。这种线性图像生成模型的闭式逆运算将二维传感器图像映射为分层三维表征：在对应真实深度的层中细节最为清晰，尽管在深度边缘处结果不准确。简而言之，我们的卷积神经网络（CNN）需要找到每个像素处细节最清晰或梯度最高的层。该像素值接近目标RGB值，对应的层索引即代表其深度。因此可以直观理解：相较于从传感器图像开始学习完整的逆变换过程，CNN更容易掌握从分层深度表征到RGB图像及深度图的映射关系。这些论点在第4节中得到了进一步讨论和实验验证。闭式解具有完全可微性，其计算成本主要由傅里叶变换决定；因此对于包含 N^2 个像素的图像，计算复杂度为 $O(N^2 \log N)$ 。

3.3.2 CNN架构

我们采用著名的U-Net风格网络架构[76]来估计四通道RGBD图像（图1）。输入数据为捕获图像与多层反卷积图像的通道级拼接结果（等式6），并通过 1×1 卷积运算转换为32通道特征图。我们的CNN包含跳跃连接和五个尺度，每个尺度包含四个连续的下采样和上采样步骤。每个尺度通过两个连续卷积层输出特征，特征通道数分别设置为[32, 64, 64, 128, 128]。所有卷积层后均接有批量归一化和修正线性单元（ReLU）。下采样与上采样操作均采用最大池化和双线性插值技术实现。我们的CNN拥有约100万个可训练参数，这一规模远小于传统MDE网络。

3.4 PSF正则化

由于内存限制，端到端（E2E）处理流程必须使用比完整传感器尺寸小得多的图像块进行训练。因此，点扩散函数（PSF）仅在图像块范围内进行优化，而在块外不受任何约束。然而，PSF可能在图像块外部产生非零能量，这会在实际应用中降低捕获图像的对比度。为避免这些伪影，我们通过正则化项对PSF的能量进行惩罚。

$$\mathcal{L}_{\text{PSF}} = \sum_{\lambda \in (\text{R}, \text{G}, \text{B})} \sum_{k=0}^{K-1} \sum_{\rho > \rho_{\text{target}}} |\text{PSF}_k(\rho, \lambda)|^2, \quad (7)$$

其中 $\text{PSF}_k(\cdot, \lambda)$ 是在整个传感器尺寸上计算得到的一维点扩散函数（PSF），而 ρ_{target} 表示目标PSF半径。尽管在整个传感器上计算多色三维PSF的计算成本较高，但由于PSF具有旋转对称性，正则化项（等式7）的计算成本较低且效果相同。在我们的训练中，采用了32像素的目标半径。

3.4.1 训练损失函数

我们使用RGB图像 $\mathcal{L}_{\text{RGB}}$ 的特征相似性、深度图 $\mathcal{L}_{\text{Depth}}$ 的L1损失以及PSF $\mathcal{L}_{\text{PSF}}$ 的正则化项来训练网络。

$$L = \psi_{\text{RGB}} \mathcal{L}_{\text{RGB}} + \psi_{\text{深度}} \mathcal{L}_{\text{Depth}} + \psi_{\text{PSF}} \mathcal{L}_{\text{PSF}}, \quad (8)$$

其中 ψ 为正则化权重。特征相似性是基于预训练VGG-16网络[77]的输入、conv1_2、conv2_2及conv3_3特征进行评估的。各特征损失值采用[0.250, 0.080, 0.250, 0.208]进行加权，具体遵循[78]中使用的微调权重。由于采用近似逆矩阵进行预条件处理时会因边缘渐变效应导致边界区域性能下降，因此在损失函数评估时排除了边界处的32个像素点。我们将 $\psi_{\text{RGB}} = \psi_{\text{深度}} = 1$ ，以及 $\psi_{\text{PSF}} = 45$ ，这些参数均为手动调整。

3.5 培训详情

E2E模型使用Adam优化器（ $\beta_1=0.9$ ， $\beta_2=0.999$ ）进行了100个训练轮次，批量大小为3，并在每个训练轮次结束时在验证集上进行评估。在100个检查点中，选择验证损失最低的那个用于测试集评估。源代码、预训练网络模型及相位掩膜可在项目网站获取：<https://www.computationalimaging.org/publications/deepopticsdfd>。

4 分析与评估

在本节中，我们描述了为评估所提出方法并将其与相关研究进行比较而开展的多项定性定量实验。

4.1 数据集

在我们的模拟实验中，我们采用FlyingThings3D数据集集中的cleanpass子集进行训练[79][80]。该数据集包含22K和8K对RGB图像及其对应的深度图，分别用于训练和测试。训练集被划分为18K和4K对，分别用于训练和验证。在训练过程中，我们采用窗口尺寸为 384×384 像素的随机裁剪以及随机水平/垂直翻转来增强训练集。目标深度范围设定为1.0米至5.0米，相机聚焦于1.7米处，光圈值为6.3。当深度图转换为 α 通道体积时，采用了逆透视采样方案[54]进行重采样。

4.2 基线比较

我们将我们的方法与几种替代方案进行了比较：

- **AiF**：将我们在模型中使用的相同深度估计CNN直接应用于真实（GT）全焦（AiF）图像。
- **Dfd**：将我们使用的相同深度估计CNN应用于传感器图像，该图像具有与我们的设置相似的光圈值（f-number），并伴有传统的（非学习所得的）散焦模糊效果。
- **海姆等人[31]**：采用我们径向对称点扩散函数（PSF）模型实现的三环相位编码孔径设计。表示这些环状结构的阶跃函数采用该文献提出的 $\tanh(100 \rho)$ 函数实现。




图3。上部：真实（GT）RGB图像（左）及所有基线方法生成的模拟传感器图像。这些基线方法（第3–6列）并未尝试估算真实的RGB图像；而本方法在应用与未应用所提出的预处理方案时生成的RGB图像估计结果。下部：所有方法生成的真实深度图与估计深度图。本方法生成的RGB图像和深度图质量在该场景中最佳。右上角展示了图像的 PSNR 值与深度图的 RMSE 值。其对应的点扩散函数（PSF）及捕获图像详见补充材料。

表1

一项消融研究，并与先前的模拟研究进行对比。上图：所有方法均按照各自论文所述方式实现，并使用各自的传感器图像作为输入。我们将每个网络的输出结果与真实深度图进行比对，并进一步将估计得到的RGB图像（或当算法未直接计算时采用的传感器图像）与全对焦参考图像进行对比。下图：展示了所提出的旋转对称DOE设计在不同线性成像方案中的效果对比：包括基于该设计的线性成像方案、结合非线性优化的线性成像方案[30]，以及本文提出的非线性模型。通过采用多种评估指标对估计得到的RGB图像和深度图进行检验，我们证明在使用相同CNN架构的所有方法中，所提出的方法表现最优。

模型	精炼	图片								深		
		MAE↓	PSNR↑	SSIM↑	MAE↓	RMSE↓	log ₁₀ ↓	δ<1.25↑	δ<1.25 ² ↑	δ<1.25 ³ ↑		
全部清晰 (AiF) 深度定义 (DfD) 海姆等人[31] 吴等人[30] 张等人[32]	—	GT	GT	GT	0.357	0.500	0.099	0.658	0.807		0.874	
	—	3.24e-2	24.95	0.711	0.097	0.228	0.039	0.929	0.965		0.979	
	—	3.28e-2	24.90	0.708	0.297	0.635	0.109	0.803	0.879		0.923	
	—	3.49e-2	24.54	0.704	0.207	0.521	0.090	0.865	0.918		0.945	
	—	3.62e-2	24.28	0.694	0.205	0.490	0.077	0.888	0.945		0.968	
线性（无 pinv）	—	2.02e-2	30.01	0.870	0.268	0.598	0.108	0.845	0.898		0.925	
线性/带平滑处理	—	1.99e-2	30.86	0.891	0.258	0.554	0.103	0.856	0.899		0.927	
线性（无 pinv）	Nonlin. w/o pinv	1.89e-2	31.43	0.900	0.127	0.264	0.065	0.901	0.952		0.964	
线性/带平滑处理	Nonlin. w/ pinv	1.83e-2	31.58	0.902	0.095	0.203	0.038	0.931	0.969		0.979	
Nonlin. w/o pinv	—	1.82e-2	31.61	0.903	0.104	0.237	0.041	0.925	0.963		0.977	
Nonlin. w/ pinv	—	1.76e-2	31.88	0.905	0.089	0.191	0.034	0.941	0.970		0.981	

- **Wu等人[30]**: PhaseCam3D方法采用的DOE尺寸为256 × 256特征点，并包含55个泽尼克系数。该DOE是通过最小化Cram均值的DOE进行初始化的。ε如该文献所述，单发射体定位的r-Rao下界。
- **Chang等人[32]**: 采用我们提出的径向对称点扩散函数（PSF）模型实现的单片透镜，可引入色差效应。所有光学参数均与我们的实验装置完全匹配。

相关研究通常仅使用 $\mathcal{L}_{\text{Depth}}$ 进行训练，并对深度图和点扩散函数（PSF）施加正则化处理。为确保光学模型间的公平比较，我们在对应研究及基线方法中均仅采用了 $\mathcal{L}_{\text{Depth}}$ 。我们根据各论文或作者提供的代码重新实现了其图像生成模型。

4.3 与先前研究的比较

图3展示了我们测试数据集中一个示例的定性定量结果。左侧显示了真实的RGB图像及深度图，随后依次呈现上述所有基线方法的结果。由于所有基线方法均未尝试生成AiF RGB图像，因此我们仅评估其RGB图像质量。

在捕获的传感器图像上，与参考AiF图像相比，我们估算得到的RGB图像表现显著优于所有这些传感器图像——这一结果并不令人意外。在比较估计深度图的质量时，传统的DfD方法表现令人惊讶地出色，远优于所有优化方法。这很可能是因为这些方法均采用了线性图像形成模型的变体，导致在深度不连续区域产生不准确的离焦模糊；而我们的DfD实现则基于非线性图像形成模型进行训练——所有方法测试均以此模型为基准。尽管如此，当结合所提出的近似逆运算（pinv）预处理技术后，我们的方法仍优于所有基线方法。若未使用预处理技术，我们的深度图质量会略逊于DfD方法，这是可以理解的：因为我们的方法需要同时重建深度图和RGB图像，而DfD仅使用相同的CNN架构来估计深度图。表1（上部分）所示的定量结果证实了这一趋势。

4.4 额外消融术

我们还通过分析其重要性，在表1（底部）中更详细地阐述了所提出的旋转对称DOE设计。

表2
评估损失函数的不同权重。

损失权重 (ψ_{RGB} ; $\psi_{\text{深度}}$)	图像 PSNR	深度 RMSE
(1.0, 1.0)	31.88	0.191
(1.0, 0.1)	33.83	0.307
(0.1, 1.0)	29.91	0.184




图4。(a)拆卸后的相机镜头与我们制造的DOE相邻，旁边配有3D打印的安装适配器。(b)所制造DOE的显微图像。深灰色区域为由NOA61制成的DOE，浅灰色区域为由铬和金制成的遮光金属孔径。右下角的黑色标尺为1毫米。(c)所设计DOE的高度分布曲线。最大高度为2.1 μm 。

如Wu等人[30]所提出的，非线性图像生成模型相较于线性模型（可选非线性细化）具有优势。在我们DOE设计的所有变体中，使用 pinv 相比未使用 pinv 的结果，均能提升图像和深度质量。此外，非线性模型的表现也优于线性变体。

在表2中，我们评估了损失函数（等式8）中图像项与深度项相对权重的影响。正如预期，两种损失项之间的相对权重直接实现了RGB PSNR 与深度 RMSE 之间的权衡；我们选择的参数组合（1.0,1.0）在这两者之间取得了良好的平衡。

5 实验评估

在本节中，我们讨论了针对训练流程所做的修改，这些修改考虑了物理限制、制造细节以及实验获得的结果。

5.1 相机原型机培训

5.1.1 额外数据集

虽然FlyingThings3D数据集提供了与RGB图像对齐的完整深度图，但这些图像均为合成生成，无法反映真实场景。因此，我们额外采用了Dual Pixels数据集[54]来学习自然场景的特征。该数据集包含通过智能手机摄像头拍摄的多视角图像及其对应的深度图，其中包含2,506张用于训练的图像和684张用于验证的图像。在训练过程中，我们仅使用五个视角中的中央视角进行训练。由于提供的深度图较为稀疏，我们对深度图进行了修复处理以获得更准确的结果。

表3

采用RGB PSNR /深度 RMSE 指标评估衍射效率（DE）。我们针对多种不同的衍射效率值（行）从头开始训练衍射光学元件（DOE）。并使用相同的及其他差异表达基因（DEs）（列）对它们进行测试。

	已测试			
	100%	75%	50%	
100%	31.88 / 0.19	30.98 / 0.36	27.66 / 0.79	
75%	29.79 / 0.27	31.74 / 0.19	29.50 / 0.35	
50%	27.91 / 0.67	30.38 / 0.34	31.24 / 0.21	

完整的深度图见[45]、[81]。虽然完成后的深度图在训练过程中用于模拟图像生成，但损失函数 $\mathcal{L}_{\text{Depth}}$ 仅在有效的（即未修复的）深度值上进行计算。训练图像从Dual Pixels和FlyingThings3D数据集中以相同概率生成。

5.1.2 具有有限衍射效率的PSF模型

正如实际应用中经常观察到的那样，我们设计的DOE衍射效率（DE）并不完美，这意味着部分入射光会直接穿透而未发生衍射。在这种情况下，成像系统的测量点扩散函数（PSF）由聚焦透镜的原始PSF与相位编码孔径产生的设计PSF共同叠加而成。当DE小于 μ 时，我们将所得PSF建模为：

$$\text{PSF} = \mu \cdot \text{PSF}_{\text{设计}} + (1 - \mu) \cdot \text{PSF}_{\text{原生}}。 \quad (9)$$

为量化我们的衍射效率（DE），我们制备了衍射光栅，并确定该制造工艺的DE约为70%。通过此次设计优化（DE），美国能源部（DOE）与网络团队共同针对我们的物理原型进行了联合优化。

我们采用400个可学习参数对DOE高度进行参数化，该参数设置与我们的制造工艺精度高度吻合。然而，在模拟点扩散函数（PSF）时，为确保精度，我们采用最近邻上采样法将这400个特征值上采样至4000像素。

为评估物理DOE中有限衍射效率（DE）的影响，我们进行了额外模拟，分析了不同衍射效率组合在训练集和测试集上的性能表现（表3）。结果不出所料：优化正确的DE始终效果最佳，而参数不匹配会降低性能；降低DE值同样会削弱整体性能。

5.1.3 点扩散函数的鲁棒优化

我们的图像形成模型假设点扩散函数（PSF）在任意深度平面上均具有平移不变性。然而在实际应用中，如补充材料所示，PSF会因光学像差而发生轻微变化；此外，对场景深度进行离散化处理无法准确模拟采样深度平面之间的PSF分布。通过实验验证我们发现，这种差异会显著影响该方法应用于实验数据时的预测精度。为解决这一问题，我们在训练过程中随机移动PSF的红色和蓝色通道，最大位移为2像素，同时保持绿色通道固定不变。此外，在每批次的PSF模拟中，每个深度平面均从等距深度平面之间随机采样；最远深度平面则随机选取于5米至100米范围内。




图5. 与深度相关的点扩散函数（PSF）。设计的PSF（上排）是通过我们的端到端模拟器进行优化的。光学缺陷导致捕获的PSF（中排）与设计值略有偏差。我们并未直接使用捕获的PSF，而是对其拟合了一个参数模型（下排），该模型随后用于优化我们的CNN。比例尺表示100 μ m。为便于可视化，我们将PSF的线性强度通过取平方根转换为振幅值。




图6. 室内与室外场景的实验捕获结果。从左至右：使用传统相机拍摄的场景图像；基于这些传统相机图像通过CNN估算出的深度图；使用我们经过优化的DOE技术的相位编码相机原型拍摄的图像；根据这些编码传感器图像由我们的算法估算出的AiF图像；以及根据这些编码传感器图像由我们的算法估算出的深度图。室内场景的俯视图（上排）及我们神经网络感受野的尺寸详见补充材料。

5.1.4 培训详情

相机设置、优化器和损失函数与消融研究中的设置相同，仅损失函数的权重有所调整。我们设定 $\psi_{\text{RGB}} = \psi_{\text{Depth}} = \psi_{\text{PSF}} = 1$ 。

5.1.5 制造与硬件实现

经过加工的DOE结构采用压印光刻技术制造。具体流程如下：首先使用灰度光刻机（MicroWriter ML3, Durham Magneto Optics）在正性光刻胶层（AZ-1512, MicroChemicals）上制作设计好的相位掩模；随后将该掩模的三维结构复制到玻璃基板上的紫外固化光学粘合剂层（NOA61, Norland Products）上。此外，玻璃基板表面还涂覆了一层铬-金-铬复合层，用于阻挡入射光线。

关于美国能源部（DOE）的相关信息，该制造工艺的详细说明详见文献[63]。

带有DOE的玻璃基板被安装在复合透镜（Yongnuo）的孔径平面上。50毫米，f/1.8）并配有定制的3D打印支架。为减少镜头内部的多重反射，在DOE与镜头之间还插入了一块黑色尼龙片。该DOE直径为5.6毫米，对应复合镜头的f/6.3光圈值。镜头安装在机器视觉相机（FLIR Grasshopper3）上，图像以16位RAW模式采集。所制备的DOE及我们的安装系统如图4所示。由于我们手动对准了DOE与遮光环（图4b），两者并非完全对齐，这导致了衍射光的存在。具体而言，我们测量到这两个组件之间的错位约为140 μ m。




图7. 实验捕获的动态场景精选帧图像。完整的动态场景可参见补充视频资料。从左上至右下依次为：传统相机拍摄的场景图像；基于该传统相机图像通过与本研究同类CNN模型估算得到的深度图；利用MiDaS[19]算法对传统图像进行深度图估算的结果；采用我们优化后的DOE技术的相位编码相机原型拍摄的图像；基于该编码传感器图像通过本研究CNN模型生成的AiF图像；以及通过...估算得到的深度图。

我们从编码后的传感器图像中提取出的CNN。

5.2 采用PSF校准进行模型优化

在将DOE安装到相机后，我们通过使用具有 $15\ \mu\text{m}$ 针孔的白色LED在不同深度下进行拍摄，记录了该系统的深度依赖性点扩散函数（PSF）。针对每个深度，对十张相机图像取平均值以降低采集噪声，并采用双线性插值法对平均图像进行去马赛克处理。如图所示。图5（中间行）显示，实际捕获的点扩散函数（PSF）与设计值（上行）存在细微差异。该差异源于多种因素，包括光学像差、复合透镜内光程长度（DOE）的错位以及制造误差。为使我们的RGB及深度估计卷积神经网络能够适应这一差异，在后处理阶段通过优化旋转对称高度图和衍射效率，使用MSE损失函数将PSF模型与实际捕获的PSF进行拟合。利用拟合后的PSF（图5下行），我们采用前述相同的训练流程对CNN进行微调，并使用固定PSF参数对采集图像进行推理。

为优化我们方法在推理过程中的鲁棒性，我们将一组水平和垂直翻转的传感器图像输入预训练网络，并取其输出结果的平均值作为最终估计值。这种推理阶段的数据增强之所以可行，得益于点扩散函数（PSF）的旋转对称性。

5.3 实验结果

我们在图6及补充视频中展示了实验获取的结果。这些示例包括在室内和室外环境中拍摄的场景。使用我们研发的相位编码孔径相机原型（第3列）拍摄的传感器图像，相较于同一场景的传统相机图像（第1列），显得更为模糊。值得注意的是，这种与深度相关的模糊效果蕴含了经过优化的信息，这些信息被我们预先训练并优化的卷积神经网络（CNN）用于生成全焦图像（第4列）和深度图（第5列）。我们生成的RGB图像质量非常出色，与参考图像相当。深度图能够精确呈现场景深度及精细细节，尤其是在底部行的植物和顶部行的玩具等复杂区域。与传统深度图相比.....

与采用与我们方法相似的CNN架构的传统相机图像（第2列）相比，我们的深度图细节显著更为丰富。它们能够轻松区分高频物体，并且整体质量优于该基线方法。

在图7及补充视频中，我们将估算得到的RGBD图像与基于AiF图像训练的基线模型以及最先进的MDE方法（MiDaS）[19]进行了对比。对于MiDaS，我们采用了作者提供的训练检查点代码（v2.1）。尽管MiDaS生成的深度图在质量上表现良好，但其估计结果仍具有相对性，且在不同帧之间缺乏一致性。相比之下，我们的方法能够以暂时一致的方式实现精确的深度估计。

最后，我们展示了有助于量化图8中我们的原型所实现深度精度的实验。在该实验中，我们拍摄了场景的五张照片，其中一本书被移动到不同已知距离处。我们在每个估计深度图中提取了一个尺寸为 50×50 像素的兴趣区域（ROI），并将估计深度值报告为该ROI的平均值。这些估计深度值（显示在各深度图的标签中）与校准后的真实距离高度一致，所有五个深度平面的总均方根误差为0.17米。

6 讨论

总之，我们提出了一种新方法，联合优化采用单个DOE实现的相位编码孔径与CNN，该方法可同时生成全焦图像及场景深度图。我们的方法具有独特性，它采用了非线性图像生成模型，该模型比以往方法能更精确地表征深度不连续处观察到的离焦模糊现象。我们的模型还采用了旋转对称的DOE/PSF设计，这使得训练阶段在计算上更具可行性——与先前研究相比，该设计将内存消耗和优化变量数量均降低了十倍之多。尽管在训练过程中，我们的非线性图像生成模型的计算成本略高于线性模型，但在测试/推理阶段，这一运算过程完全由光学系统物理实现，因此不会增加额外计算负担。

我们注意到，DOE的其他参数化方式同样能带来计算优势。例如，与Sitzmann等人[62]和Wu等人[30]的研究类似，我们可以采用与我们的旋转对称模型参数数量相匹配的Zernike表示法来描述DOE。尽管这两种方法需要优化的参数数量相同，但泽尼克表示法虽然能获得更平滑的图像效果，却需要高出一个数量级的内存资源——而这正是旋转对称模型所解决的核心问题。后者仅需进行一维计算即可完成整个旋转对称二维点扩散函数（PSF）的计算；而泽尼克表示法则要求所有相关运算均需在二维空间内以全分辨率完成。由于我们采用的是端到端可微分模型，这些二维计算过程中需要在计算图中存储大量中间变量，使得基于泽尼克的方法在内存占用方面与其他方案不相上下。

6.1 局限性与未来研究方向

我们采用相位编码孔径的主要局限性之一在于其衍射效率有限，且所测点扩散函数（PSF）存在一定程度的偏移方差（详见补充材料）。




图 8. 实验性定量分析。对包含多件物体（其中包括一本书）的场景进行了多次拍摄，书籍处于不同深度位置。该书籍的深度通过估算的深度图确定。所有五个深度平面的均方根误差为0.17 米。

（材料）。在本项目中，我们通过优化衍射光学元件（DOE）、充分考虑其有限的衍射效率，并在训练过程中对点扩散函数（PSF）进行随机抖动处理，成功解决了这些问题，从而使系统能够有效应对微小位移的影响。然而，若能进一步优化光学元件的制造工艺与衍射效率，同时改进全集成系统的对准与校准精度，同类计算成像系统的性能仍有显著提升空间。

在我们获得的结果中（图6），我们还观察到纹理区域的部分边缘出现在估算的深度图中。这些残留的缺陷可能源于我们的图像生成模型与物理系统之间的任何差异，包括点扩散函数（PSF）存在的微小空间变化、光学像差，或衍射光学元件（DOE）的估计衍射效率与实际值之间存在轻微偏差。此外，为控制内存占用量，我们仅在三个离散波长下模拟PSF，而物理传感器实际上覆盖了较宽的光谱范围。最后，我们将场景深度离散化为多个层级，而物理模型本身是连续的。我们在训练过程中通过引入PSF抖动来部分缓解这些问题，但并非所有物理效应都能被完美模拟。因此，尽管我们的方法相比相关技术取得了显著改进，实验结果仍有进一步提升的空间。

MDE 的网络架构与训练流程在性能上已显著提升，但代价是复杂度增加（例如[18]、[19]）。这些纯软件方法在估算场景相对深度信息方面非常成功，却无法可靠地估算场景的绝对深度。基于深度学习的散焦类型方法能够在纹理和深度边缘清晰可辨的区域准确估算出可靠的场景绝对深度。然而，我们及该领域的先前研究采用的网络规模相对较小，其处理能力不及现代单目深度估计器，因此可能无法像现有方法那样有效捕捉上下文线索。因此，探索能够同时捕捉（编码式）散焦模糊所提供的物理信息以及上下文线索的优化网络架构至关重要。

图像场景信息。最后，若采用独立网络分别处理图像与深度重建任务，可进一步提升网络性能，但会增加内存消耗。

6.2 结论

端到端（E2E）光学与图像处理优化这一新兴范式，在多种计算光学应用中展现出巨大潜力。我们认为，基于深度的点扩散函数（PSF）设计——例如用于被动估算场景深度——是该研究范式中最具前景的方向之一，其应用潜力涵盖机器人技术、自动驾驶、人机交互等多个领域。通过我们的研究工作，我们在实现这些应用场景中联合优化的软硬件系统的实际应用方面取得了显著进展。

致谢

C.M.N.的研究工作获得美国国家科学基金会（NSF）研究生研究奖学金（项目编号 DGE -1656518）资助；C.A.M.的研究工作获斯坦福大学情报界博士后研究奖学金计划资助，该计划由橡树岭科学与教育研究所（ORISE）根据美国能源部与国家情报总监办公室（ODN）签订的跨机构协议实施；G.W.的研究工作还获得NSF资助项目1553333和1839974、斯隆奖学金以及ARO提供的 PECASE 支持。本研究的部分工作在斯坦福纳米共享设施（SNSF）完成，该设施由美国国家科学基金会（项目编号 ECCS -2026822）资助。我们谨向以下 Blender Swap 用户致谢，感谢他们提供的模型用于我们的 Blender 渲染：pujiyanto（木质椅子）、wawanbreton（蓝色沙发）、bogiva（水壶）、danikreuter（Vespa摩托车）、animatedheaven（篮球）、tikiteyboo（酒瓶箱）、TowerCG（蜘蛛植物）、oenvoyage（存钱罐）、JSantel（香蕉）、Rohit Miraje（紫色吉普车）、mStuff（橡皮鸭）以及 sudeepsingh（蓝色汽车）。

参考文献

- [1] 叶明、E. Johns、A. Handa、L. Zhang、P. Pratt 和 G.-Z. Yang, 《基于立体图像对的自监督孪生网络在机器人手术深度估计中的应用》, *arXiv:1705.08260*, 2017。
- [2] A. Sabnis 和 L. Vachhani, 《基于单幅图像的机器人应用深度估计》, 载于《IEEE 智能计算系统最新进展》, 2011年, 第102-106页。
- [3] N. Metni、T. Hamel 和 F. Derkx, 《基于自适应深度估计的空中机器人系统视觉跟踪控制》, 收录于《IEEE 决策与控制会议》, 2005年, 第6078-6084页。
- [4] J. Stowers、M. Hayes 和 A. Bainbridge-Smith, 《利用 Microsoft Kinect 传感器提供的深度图实现四旋翼直升机的高度控制》, 收录于《IEEE 国际机电一体化会议》, 2011年, 第358-362页。
- [5] Y. Wang、W.-L. Chao、D. Garg、B. Hariharan、M. Campbell 和 K. Q. Weinberger, “基于视觉深度估计的伪激光雷达: 弥合自动驾驶领域三维物体检测的技术差距”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2019年, 第8445-8453页。
- [6] 陈X、马H、万J、李B和T.夏, “用于自动驾驶的多视角3D目标检测网络”, 计算机视觉与模式识别会议 (CVPR), 2017年, 第1907-1915页。
- [7] W. Lee、N. Park 和 W. Woo, 《深度辅助的实时三维物体检测在增强现实中的应用》, 载于《国际人工现实与共存会议 (ICAT)》, 第11卷第2期, 2011年, 第126-132页。
- [8] J. Kopf、K. Matzen、S. Alsisan、O. Quigley、F. Ge、Y. Chong、J. Patterson、J.-M. Frahm、S. Wu、M. Yu 等, 《单次拍摄三维摄影》, *ACM 图形学汇刊 (TOG)*, 第39卷, 第4期, 第76-1页, 2020年。
- [9] A. Saxena、S. H. Chung 和 A. Y. Ng, “从单眼图像中学习深度”, 载于《神经信息处理系统进展》, 2006年, 第1161-1168页。
- [10] D. Eigen、C. Puhrsch 和 R. Fergus, 《基于多尺度深度网络的单张图像深度图预测》, 载于《神经信息处理系统进展》, 2014年, 第2366-2374页。
- [11] B. 李、C. 沈、Y. 戴、A. 范登亨格尔和 M. 他, 《基于深度特征回归和层次条件随机场的单目图像深度与表面法线估计》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2015年, 第1119-1127页。
- [12] F. Liu、C. Shen、G. Lin 和 I. Reid, 《利用深度卷积神经网络从单目图像中学习深度》, 《IEEE 模式分析与机器智能汇刊》, 第38卷, 第10期, 第2024-2039页, 2015年。
- [13] I. Laina、C. Rupprecht、V. Belagiannis、F. Tombari 和 N. Navab, 《基于全卷积残差网络的深度预测》, 收录于《三维视觉国际会议 (3DV)》, 2016年, 第239-248页。
- [14] D. Xu、E. Ricci、W. Ouyang、X. Wang 和 N. Sebe, “多尺度连续CRFs作为单目深度估计的序列深度网络”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2017年, 第5354-5362页。
- [15] J. Li、R. Klein 和 A. Yao, 《一种基于单 RGB 图像的双流网络用于估算精细尺度深度图》, 收录于《国际计算机视觉会议 (ICCV)》, 2017年, 第3372-3380页。
- [16] H. Fu、M. Gong、C. Wang、K. Batmanghelich 和 D. 陶, “用于单目深度估计的深度序数回归网络”, 计算机视觉与模式识别会议 (CVPR), 2018年, 第2002-2011页。
- [17] Y. Cao、T. Zhao、K. Xian、C. Shen、Z. Cao 和 S. Xu, “基于增强序数深度关系的单目深度估计”, *arXiv:1806.00585*, 2018。
- [18] I. Alhashim 和 P. Wonka, 《通过迁移学习实现高质量单目深度估计》, *arXiv:1812.11941*, 2018。
- [19] R. Ranftl、K. Lasinger、D. Hafner、K. Schindler 和 V. Koltun, 《迈向鲁棒的单目深度估计: 混合数据集以实现零样本跨数据集迁移》, *arXiv:1907.01341*, 2020年。
- [20] A. P. Pentland, 《景深的新定义》, 《IEEE 模式分析与机器智能汇刊》, 第PAMI-9卷, 第4期, 第523-531页, 1987年。
- [21] 渡边M. 和 Nayar S.K., 《基于离焦的被动深度计算的理性滤波器》, 《国际计算机视觉杂志》, 第27卷, 第203-225页, 1998年。
- [22] P. Favaro, “通过非局部均值正则化恢复薄结构——及其在离焦深度测量中的应用”, 计算机视觉与模式识别会议 (CVPR), 2010年, 第1133-1140页。
- [23] P. Trounev, F. Champagnat、G. Le Besnerais、J. Sabater、T. Avignon 和 J. Idier, 《基于色差和离焦深度的方法进行被动深度估计》, [25] M. 卡瓦略、B. 莱索、P. 特鲁夫é-Peloux、A. Almansa 和 F. Champagnat, 《离焦产生的深度信息: 离焦模糊如何利用密集神经网络改进三维估计?》, 收录于《欧洲计算机视觉会议 (ECCV)》, 2018年, 第0-0页。
- [26] A. Levin、R. Fergus、F. Durand 和 W. T. Freeman, 《采用编码光圈的传统相机获取图像与深度》, *ACM 图形学汇刊 (TOG)*, 第26卷, 第3期, 第70-es 页, 2007年。
- [27] A. Veeraraghavan、R. Raskar、A. Agrawal、A. 莫汉与J. 图姆布林, 《斑点摄影: 用于外差光场及编码孔径重聚焦的掩模增强相机》, *ACM 图形学汇刊 (TOG)*, 第26卷第3期, 第69页, 2007年。
- [28] C. Zhou、S. Lin 和 S. Nayar, “用于通过离焦获取深度的编码孔径对”, 载于《国际计算机视觉会议 (ICCV)》, 2009年, 第325-332页。
- [29] P. A. Shedliger、S. Mohan 和 K. Mitra, 「基于数据的编码孔径设计用于深度恢复」, 载于《国际图像处理会议 (ICIP)》, 2017年, 第56-60页。
- [30] Y. Wu、V. Boominathan、H. Chen、A. Sankaranarayanan 和 A. Veeraraghavan, “Phasecam3d——用于被动单视角深度估计的相位掩模学习方法”, 收录于《国际计算摄影会议 (ICCP)》, IEEE, 2019年, 第1-12页。
- [31] H. Haim、S. Elmalem、R. Giryes、A. M. Bronstein 和 E. Marom, 《基于深度学习相位编码掩模的单幅图像深度估计》, *IEEE 计算成像汇刊*, 第4卷, 第3期, 第298-310页, 2018年。
- [32] J. Chang 和 G. Wetzstein, “用于单目深度估计和三维物体检测的深度光学技术”, 收录于《国际计算机视觉会议 (ICCV)》, 2019年。
- [33] J. A. Marshall、C. A. Burbeck、D. Ariely、J. P. Rolland 和 K. E. Martin, 《遮挡边缘模糊: 相对视觉深度的线索》, 《美国光学学会杂志A》, 第13卷, 第4期, 第681-688页, 1996年4月。
- [34] S. E. Palmer 和 T. Ghose, 《极端边缘: 深度感知与图形-背景组织的重要线索》, 《心理科学》, 第19卷, 第1期, 第77-83页, 2008年。
- [35] M. Zannoli、G. D. Love、R. Narain 和 M. S. Banks, 《遮挡条件下的模糊效应与深度感知》, 《视觉杂志》, 第16卷第6期, 第17-17页, 2016年。
- [36] L. He、M. Yu 和 G. Wang, “Spindle-net: 基于扩张核方法的单目深度推理CNN网络”, 载于《国际模式识别会议 (ICPR)》, 2018年, 第2504-2509页。
- [37] Heo M., Lee J., Kim K.-R., Kim H.-U. 与 Kim C.-S., “基于全条带掩蔽及可靠性优化的单目深度估计”, 载于《欧洲计算机视觉会议 (ECCV)》, 2018年, 第36-51页。
- [38] F. 托西、F. 阿莱奥蒂、M. Poggi 和 S. Mattoccia, 《基于传统立体视觉知识的学习单目深度估计》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2019年, 第9799-9809页。
- [39] H. Zhan、R. Garg、C. Saroj Weerasekera、K. Li、H. Agarwal 和 I. Reid, “基于深度特征重建的单目深度估计与视觉里程计的无监督学习”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2018年, 第340-349页。
- [40] C. Godard、O. Mac Aodha 和 G. J. Brostow, “基于左右一致性的一目无监督深度估计”, 载于《计算机视觉与模式识别会议 (CVPR)》, 2017年, 第270-279页。
- [41] T.-C. Wang、A. A. Efros 和 R. Ramamoorthi, 《基于光场相机的遮挡建模深度估计》, *IEEE 图形分析与机器智能汇刊*, 第38卷, 第11期, 第2170-2181页, 2016年。
- [42] X. Qi、R. Liao、Z. Liu、R. Urtasun 和 J. Jia, “Geonet: 用于联合深度与表面法线估计的几何神经网络”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2018年, 第283-291页。
- [43] Z. 杨、P. 王、Y. 王、W. 徐与 R. Nevatia, 《乐高: 通过观看视频一次性掌握几何知识》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2018年, 第225-234页。
- [44] A. Geiger、P. Lenz、C. Stiller 和 R. Urtasun, 《视觉与机器人技术的融合: kitti数据集》, 《国际机器人研究杂志》, 第32卷, 第11期, 第1231-1237页, 2013年。
- [45] N. Silberman、D. Hoiem、P. Kohli 和 R. Fergus, 《基于rgbd图像的室内分割与支撑推理》, 收录于《欧洲计算机视觉会议 (ECCV)》, 2012年, 第746-760页。
- [46] J.-H. Lee 和 C.-S. Kim, 《基于相对深度图的单目深度估计》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2019年, 第9729-9738页。

《应用光学》，第52卷，第29期，第7152–7164页，2013年。

[24] E. Alexander, Q. Guo, S. Koppal, S. Gortler 和 T. Zickler, 《焦点流: 利用离焦与差分运动测量距离与速度》，收录于《欧洲计算机视觉会议 (ECCV)》，2016年，第667–682页。

[47] J.-H. Lee, M. Heo, K.-R. Kim 和 C.-S. Kim, 《基于傅里叶域分析的单图像深度估计》，收录于《计算机视觉与模式识别会议 (CV-PR)》，2018年，第330–339页。

- [48] P. P. Srinivasan, R. Garg, N. Wadhwa, R. Ng 和 J. T. Barron, “单目深度估计的孔径监督技术”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2018年, 第6393–6401页。
- [49] L. He, G. Wang 和 Z. Hu, 《利用深度神经网络嵌入焦距从单张图像中学习深度》, *IEEE 图像处理汇刊*, 第27卷, 第9期, 第4676–4689页, 2018年。
- [50] M. Nishimura, D. B. Lindell, C. Metzler 和 G. Wetzstein, “利用单一瞬态信号消除单眼深度估计的歧义”, 收录于《欧洲计算机视觉会议 (ECCV)》, 2020年。
- [51] S. K. Nayar 和 Y. Nakagawa, 《从焦点获取形状》, *IEEE 图形分析与机器学习汇刊*, 第16卷, 第8期, 第824–831页, 1994年。
- [52] M. Subbarao 和 G. Surya, 《从失焦获取深度: 一种空间域方法》, 《国际计算机视觉杂志》, 第13卷, 第3期, 第271–294页, 1994年。
- [53] H. Tang, S. Cohen, B. Price, S. Schiller 和 K. N. Kutulakos, 《野外环境中的离焦深度》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2017年, 第2740–2748页。
- [54] R. Garg, N. Wadhwa, S. Ansari 和 J. T. Barron, 《利用双像素实现单摄像头深度估计》, 载于《国际计算机视觉会议 (ICCV)》, 2019年, 第7628–7637页。
- [55] C. Zhou, S. Lin 和 S. K. Nayar, 《基于离焦及离焦去模糊技术的深度编码孔径对》, 《国际计算机视觉杂志》, 第93卷第1期, 第53–72页, 2011年。
- [56] S. R. P. Pavan, M. A. Thompson, J. S. Biteen, S. J. Lord, N. Liu, R. J. Twieg, R. Piestun 和 W. Moerner, “通过使用双螺旋点扩散函数实现超越衍射极限的三维单分子荧光成像”, 《美国国家科学院院刊》, 第106卷, 第9期, 第2995–2999页, 2009年。
- [57] A. Levin, S. W. Hasinoff, P. Green, F. Durand 和 W. T. Freeman, 《计算相机用于景深扩展的四维频率分析》, *ACM 图形学汇刊 (TOG)*, 第28卷, 第3期, 第1–14页, 2009年。
- [58] A. Chakrabarti, “通过反向传播实现学习型传感器复用设计”, 载于《神经信息处理系统进展》, 2016年, 第3081–3089页。
- [59] 王林、张涛、傅勇和H.黄, “HyperReconNet: 压缩式高光谱成像的联合编码孔径优化与图像重建”, *IEEE 图像处理汇刊*, 第28卷, 第5期, 第2257–2270页, 2019年5月。
- [60] E. Nehme, D. Freedman, R. Gordon, B. Ferdman, L. E. Weiss, O. Alalouf, R. Orange, T. Michaeli 和 Y. Shechtman, “DeepSTORM3 D: 基于深度学习的高密度三维定位显微技术与点扩散函数设计”, *Nature Methods*, 第17卷, 第734–740页, 2020年。
- [61] Q. Sun, J. Zhang, X. Dun, B. Ghanem, Y. Peng 和 W. Heidrich, 《端到端学习式光学编码超分辨率SPAD相机》, *ACM 图形学汇刊 (TOG)*, 第39卷, 2020年。
- [62] V. Sitzmann, S. Diamond, Y. Peng, X. Dun, S. Boyd, W. Heidrich, F. Heide 和 G. Wetzstein, “为消色差扩展景深和超分辨率成像实现光学与图像处理的端到端优化”, *ACM 图形学汇刊 (TOG)*, 第37卷, 第4期, 第1–13页, 2018年。
- [63] X. Dun, H. Ikoma, G. Wetzstein, Z. Wang, X. Cheng 和 Y. Peng, 《用于全谱计算成像的学得旋转对称衍射消色差系统》, *Optica*, 第.....卷, 第7卷, 第8期, 第913–922页, 2020年。
- [64] C. A. Metzler, H. Ikoma, Y. Peng 和 G. Wetzstein, “用于单次拍摄高动态范围成像的深度光学技术”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2020年, 第1375–1385页。
- [65] Q. Sun, E. Tseng, Q. Fu, W. Heidrich 和 F. Heide, “单次拍摄高动态范围成像中的秩1衍射光学学习技术”, 收录于《计算机视觉与模式识别会议 (CVPR)》, IEEE, 2020年。
- [66] J. Chang, V. Sitzmann, X. Dun, W. Heidrich 和 G. Wetzstein, 《采用优化衍射光学技术的混合光子卷积神经网络用于图像分类》, *Scientific Reports*, 第8卷, 第1期, 第12324页, 2018年。
- [67] J. Martel, L. Mueller, S. Carey, P. Dudek 和 G. Wetzstein, 《神经传感器: 利用可编程传感器学习像素曝光参数以实现HDR成像与视频压缩感知》, 《IEEE 模式分析与机器学习汇刊》, 第42卷, 第1642–1653页, 2020年。
- [68] 李Y、齐M、古尔夫R、魏M、热诺夫R、库图拉科斯K.N.和W.海德里希, 《基于Anderson加速展开网络的端到端视频压缩感知》, 收录于《国际计算摄影会议 (ICCP)》, 2020年, 第1–12页。
- [69] G. Wetzstein, A. Ozcan, S. Gigan, S. Fan, D. Englund, M. Soljacic, C. Denz, D. A. B. Miller 和 D. Psaltis, 《基于深度光学与光子学的人工智能推理》, 《自然》, 第588卷, 2020年。
- [70] S.-H. Baek, H. Ikoma, D. S. Jeon, Y. Li, W. Heidrich, G. Wetzstein 和 M. H. Kim, “基于学习型衍射光学的端到端高光谱深度成像”, *arXiv:2009.00436*, 2020年。
- [71] J. W. Goodman, 《傅里叶光学导论》, Roberts and Company出版社, 2005年。
- [72] S. W. Hasinoff 和 K. N. Kutulakos, 《一种基于图层的可变孔径摄影恢复框架》, 收录于《国际计算机视觉会议 (ICCV)》, IEEE, 2007年, 第1–8页。
- [73] T. Zhou, R. Tucker, J. Flynn, G. Fyffe 和 N. Snavely, 《立体放大: 基于多平面图像的学习视图合成》, *ACM 图形学汇刊 (TOG)*, 第37卷, 第4期, 2018年。
- [74] 张X、马岑K、阮V、姚D、张Y和R. Ng, 《“用于休闲视频拍摄的合成散焦与预判自动对焦”》, *ACM 图形学汇刊 (TOG)*, 第38卷, 第4期, 2019年7月。
- [75] S. J. Reeves, 《无需边界伪影的快速图像恢复》, *IEEE 图像处理汇刊*, 第14卷, 第10期, 第1448–1453页, 2005年。
- [76] O. Ronneberger, P. Fischer 和 T. Brox, 《U-net: 用于生物医学图像分割的卷积网络》, 收录于《国际医学图像计算与计算机辅助干预会议 (MIC CAI)》, 2015年, 第234–241页。
- [77] K. Simonyan 和 A. Zisserman, 《用于大规模图像识别的超深度卷积网络》, 收录于《国际学习表征会议 (ICLR)》, 2015年。
- [78] J. Flynn, M. Broxton, P. Debevec, M. DuVall, G. Fyffe, R. Overbeck, N. Snavely 和 R. Tucker, 《DeepView: 基于学习梯度下降的视图合成》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2019年, 第2367–2376页。
- [79] N. Mayer, E. Ilg, P. Hausser, P. Fischer, D. Cremers, A. Dosovitskiy 和 T. Brox, “用于训练卷积网络以实现视差、光流及场景流估计的大型数据集”, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2016年, 第4040–4048页。
- [80] E. Ilg, N. Mayer, T. Saikia, M. Keuper, A. Dosovitskiy 和 T. Brox, 《FlowNet 2.0: 基于深度网络的光流估计技术演进》, 收录于《计算机视觉与模式识别会议 (CVPR)》, 2017年, 第2462–2470页。
- [81] A. Levin, D. Lischinski 和 Y. Weiss, 《基于优化的着色技术》, *ACM 图形学汇刊 (TOG)*, 第23卷, 第3期, 第689–694页, 2004年8月。




池间隼人 (Hayato Ikoma) 是美国斯坦福大学电气工程专业的博士生。他毕业于东京大学 (日本), 获得电气工程学士学位; 并在京都大学 (日本)、麻省理工学院 (美国) 以及巴黎高等师范学院 (École Normale Supérieure) 分别取得硕士学位。埃里埃尔·德·卡尚 (法国)。他的研究重点在于开发适用于相机和荧光光学显微镜的计算成像技术。



辛迪·M·阮 (Cindy M. Nguyen) 于2019年在美国加利福尼亚州斯坦福大学获得生物工程学士学位, 目前正攻读博士学位。美国加利福尼亚州斯坦福市斯坦福大学电气工程专业的学生。她的研究兴趣在于将优化方法应用于计算机视觉与计算成像领域的问题。她曾荣获美国国家科学基金会研究生研究奖学金。

克里斯托弗·A·梅茨勒（IEEE会士）现任马里兰大学帕克分校计算机科学助理教授（兼任电气与计算机工程系助理教授）。他分别于2013年、2014年和2019年在美国德克萨斯州休斯顿的莱斯大学获得电气与计算机工程学士、硕士及博士学位，并近期在斯坦福大学计算成像实验室完成了为期两年的博士后研究。他曾担任情报界博士后研究员及美国国家科学基金会研究生项目资助学者。

他是研究院士、美国国防部 NDSEG 研究员以及美国国家航空航天局德克萨斯太空资助联盟研究员。其研究运用机器学习与统计信号处理技术，开发出基于数据驱动的解决方案，以应对复杂的成像难题。



运用波光学原理。

彭一凡（Evan Peng）（IEEE会员）于2018年在加拿大 British Columbia 大学获得 Computer Science 博士学位，并分别于2013年和2010年在中国浙江大学获得光学科学与工程专业的理学硕士和理学学士学位。目前，他担任斯坦福大学电气工程系博士后研究员。他的研究重点在于融合光学与计算技术，以实现新型成像模式。他目前正在致力于开发计算相机及显示系统。

戈登·韦茨斯坦（IEEE资深会员）毕业于包豪斯大学，并获得荣誉学位。他出生于德国魏玛，并于2011年在加拿大不列颠哥伦比亚大学获得计算机科学博士学位。目前，他是美国加利福尼亚州斯坦福大学电气工程系助理教授，同时兼任计算机科学系助理教授。他担任斯坦福计算成像实验室主任，并兼任斯坦福图像系统工程中心的教员联合主任。其研究领域涵盖计算机图形学与视觉技术、计算光学以及应用视觉科学的交叉学科，研究成果在下一代成像技术、显示设备、可穿戴计算设备及显微镜系统等领域具有广泛的应用前景。他曾荣获美国国家科学基金会（NSF）职业成就奖及阿尔弗雷德·P.奖。斯隆奖学金、ACM SIGGRAPH重要新锐研究者奖、总统早期职业科学家与工程师奖（PECASE）、SPIE 早期职业成就奖、特曼奖学金、冈川研究基金、2017年度电子成像科学家奖、阿兰·富尼耶博士论文奖、拉瓦尔虚拟奖，以及在 ICCP 2011、2014、2016年和 ICIP 2016会议上获得的最佳论文与演示奖。

